

**PROJETO INTEGRADOR CANNOLI
4CCOMP - FECAP**

ANÁLISE INFERENCIAL DE DADOS

Entrega 2

Prof. Rodnil Lisboa

LARISSA DE ALMEIDA LIRA OLIVEIRA - 24026849

VINICIUS CARDOSO DE LIMA – 24026851

LUAN ROCHA DA SILVA - 24026633

SAULO RIBEIRO SANTOS – 24026911

1. STORE e STOREORDER

1.1 Análise total dos dados

O coeficiente de determinação (R^2) obtido foi de **0.999**. Isso indica que 99,9% da variabilidade do valor total (totalamount) é explicada pelas variáveis independentes (subtotalamount, discountamount e taxamount). O ajuste é extremamente alto, o que é esperado, já que o valor total de um pedido é geralmente uma soma direta dessas componentes.

O comando usado foi esse:

```
dados_modelagem <- na.omit(dados[, c("totalamount", "subtotalamount",  
"discountamount", "taxamount")])
```

```
modelo <- lm(totalamount ~ subtotalamount + discountamount + taxamount, data =  
dados_modelagem)
```

```
resumo <- summary(modelo)  
print(resumo)
```

```
coeficientes <- coef(modelo)  
print(coeficientes)
```

O intercepto no valor de -0.1311314 representa o valor base quando todas as outras variáveis são zero. Sendo próximo de zero, indica que não há um custo fixo "invisível" significativo.

O subtotalamount foi de 1.0001252 indicando que para cada R\$ 1,00 adicionado ao subtotal, o valor total do pedido aumenta exatamente R\$ 1,00. É uma relação direta e perfeita. O P-value < 0.05 confirma que esta é a variável mais influente.

Já o discountamount foi de -0.9771288. O sinal negativo mostra que o desconto subtrai do total. Para cada R\$ 1,00 de desconto aplicado, o valor final cai aproximadamente R\$ 0,98.

E o da taxamount 0.9951807, como o valor é positivo, cada real de taxa aumenta o valor total em um real.

Todas as variáveis apresentaram um P-value extremamente baixo (próximo de zero), o que significa que todas são estatisticamente significantes para prever o totalamount

2. Impacto na campanha

Para calcular a taxa de conversão e o impacto no faturamento, realizamos o cruzamento entre os registros de disparos de campanha (CAMPAIGN.CSV) e os pedidos convertidos (CAMPAIGNxORDER.CSV).

```
library(readr)
library(dplyr)
library(lubridate)

campanha <- read_csv("CAMPAIGN.CSV")
campanha_pedido <- read_csv("CAMPAIGNxORDER.CSV")
pedidos_loja <- read_csv("STOREORDER.csv")

campanha$sendat <- as.POSIXct(campanha$sendat, format="%Y-%m-%d %H:%M:%OS",
tz="UTC")
pedidos_loja$createdat <- as.POSIXct(pedidos_loja$createdat, format="%Y-%m-%d
%H:%M:%OS", tz="UTC")

clientes_alcançados <- length(unique(campanha$customerid))
clientes_convertidos <- length(unique(campanha_pedido$customerid))
taxa_conversao <- (clientes_convertidos / clientes_alcançados) * 100

faturamento_total <- sum(pedidos_loja$totalamount, na.rm = TRUE)
faturamento_campanha <- sum(campanha_pedido$totalamount, na.rm = TRUE)

data_referencia <- as.Date("2025-12-30")

fat_antes <- pedidos_loja %>%
  filter(as.Date(createdat) >= data_referencia - days(7) & as.Date(createdat) <
data_referencia) %>%
  summarise(total = sum(totalamount, na.rm = TRUE))

fat_depois <- pedidos_loja %>%
  filter(as.Date(createdat) >= data_referencia & as.Date(createdat) <= data_referencia +
days(7)) %>%
  summarise(total = sum(totalamount, na.rm = TRUE))

print(paste("Taxa de Conversao:", taxa_conversao, "%"))
print(paste("Faturamento Atribuido:", faturamento_campanha))
print(paste("Faturamento 7 dias antes:", fat_antes$total))
print(paste("Faturamento 7 dias depois:", fat_depois$total))
```

Taxa de Conversão:

Clientes Alcançados: 19.395 clientes únicos que receberam comunicações.

Clientes Convertidos: 8.761 desses clientes realizaram ao menos um pedido após a campanha.

Taxa de Conversão: 45,23%.

O faturamento total registrado no sistema é de R\$ 6.818.316,81, e o faturamento diretamente atribuído às campanhas (pedidos vinculados a uma ação) é de R\$ 5.843.983,53. Isso significa que 85,71% do faturamento total da empresa possui influência direta de campanhas de marketing.

Tomando como exemplo uma data de pico de disparos, 30/12/2025 no final do ano, o faturamento 7 dias antes da campanha foi de R\$ 350.440,23 e o faturamento 7 dias depois da campanha foi de R\$ 340.342,41.

Apesar de ter tido uma queda no valor, a campanha pode ter ajudado a segurar uma queda ainda mais brusca, mas ela sozinha não teve força para superar a barreira da sazonalidade natural do início de janeiro pós festividades.

Tabela 1 — Estimativa inferencial da taxa de conversão das campanhas.

Métrica	Resultado
Taxa de conversão observada	45,23%
Limite inferior do IC (95%)	44,53%
Limite superior do IC (95%)	45,94%
p-value	< 2,2e-16

3. Avaliação do Modelo de Regressão

O modelo de regressão linear apresentou coeficiente de determinação (R^2) de 0,999, indicando que aproximadamente 99,9% da variação do valor total dos pedidos é explicada pelas variáveis independentes utilizadas no modelo.

Esse resultado já era esperado, considerando que o totalamount é diretamente composto por subtotalamount, discountamount e taxamount, gerando uma relação estrutural muito forte entre as variáveis.

O erro padrão residual foi de 1,778, indicando baixa diferença média entre os valores observados e estimados pelo modelo, o que demonstra alta precisão nas previsões.

O teste F apresentou valor de $3,924 \times 10^7$ com p-value inferior a $2,2e-16$, confirmando que o modelo é estatisticamente significativo.

Além disso, todas as variáveis independentes apresentaram p-values inferiores a 0,05, reforçando sua relevância estatística na explicação do valor total dos pedidos.

Tabela 2 — Coeficientes estimados do modelo de regressão linear.

Variável	Coeficiente	Erro Padrão	t-value	p-value	Significância
Intercepto	-0,131	0,0108	-12,1	$< 2e-16$	***
subtotalamount	1,000	0,000093	10738,5	$< 2e-16$	***
discountamount	-0,977	0,000787	-1241,7	$< 2e-16$	***
taxamount	0,995	0,001159	858,4	$< 2e-16$	***

Tabela 3 — Indicadores de ajuste do modelo de regressão.

Indicador	Valor
Erro padrão residual	1,778
R^2	0,999
R^2 ajustado	0,999
F-statistic	$3,924 \times 10^7$
p-value global	$< 2,2e-16$

4. Intervalo de Confiança

`confint(modelo, level = 0,95)`

Foram calculados intervalos de confiança de 95% para os coeficientes do modelo de regressão, utilizando o método padrão baseado na distribuição t de Student.

Os resultados indicaram que todos os intervalos estão extremamente próximos dos valores estimados e não incluem o valor zero, reforçando a significância estatística das variáveis.

Essa proximidade é esperada devido à relação estrutural entre as variáveis, uma vez que o valor total do pedido é composto diretamente pelos seus componentes (subtotal, desconto e taxa).

Dessa forma, os intervalos de confiança confirmam não apenas a significância, mas também a estabilidade dos coeficientes, indicando baixa variabilidade nas estimativas.

Tabela 4 — Intervalos de confiança dos coeficientes do modelo (95%).

Variável	Limite Inferior (2,5%)	Limite Superior (97,5%)
Intercepto	-0,1524	-0,1099
subtotalamount	0,9999426	1,0003077
discountamount	-0,9786713	-0,9755864
taxamount	0,9929083	0,9974531

5. Teste de Hipótese

```
antes <- pedidos_loja %>%
  filter(as.Date(createdat) >= data_referencia - 7 & as.Date(createdat) < data_referencia) %>%
  pull(totalamount)

depois <- pedidos_loja %>%
  filter(as.Date(createdat) >= data_referencia & as.Date(createdat) <= data_referencia + 7)
  %>%
  pull(totalamount)

t.test(antes, depois)
```

Para avaliar o impacto das campanhas no faturamento, foi realizado um teste de hipótese comparando os valores médios dos pedidos antes e depois da campanha.

A hipótese nula (H_0) considera que **não existe diferença estatisticamente significativa no faturamento médio entre os períodos**, enquanto a hipótese alternativa (H_1) considera que **há diferença significativa entre os períodos analisados**.

Foi aplicado o **teste t de Welch para amostras independentes**, método apropriado quando não se assume igualdade entre as variâncias dos grupos, tornando a análise mais robusta.

Os resultados do teste apresentaram **estatística t = 2,0504** e **p-value = 0,04035**, valor inferior ao nível de significância de 5% ($\alpha = 0,05$). Dessa forma, **rejeita-se a hipótese nula**, indicando evidências estatísticas de diferença entre os períodos antes e depois da campanha.

Entretanto, embora a diferença seja estatisticamente significativa, sua magnitude prática foi relativamente pequena. A média do faturamento por pedido passou de **R\$ 60,54 antes da campanha** para **R\$ 59,02 após a campanha**.

Esse resultado sugere que a campanha pode ter influenciado o comportamento das vendas, porém fatores externos — como sazonalidade, perfil de consumo e período analisado — provavelmente também exerceram influência sobre os resultados observados.

Tabela 5 — Resultado do teste t para comparação do faturamento.

Métrica	Resultado
Média antes da campanha	R\$ 60,54
Média depois da campanha	R\$ 59,02
Estatística t	2,0504
p-value	0,04035
IC inferior (95%)	0,0668
IC superior (95%)	2,9693

Figura 1 — Distribuição do faturamento antes e depois da campanha.





Figura 2 — Comparação da média do faturamento por pedido antes e depois da campanha.



6. Análise Crítica do Modelo

Apesar do modelo apresentar excelente desempenho estatístico, é necessário avaliar criticamente sua construção.

As variáveis independentes utilizadas fazem parte da composição direta do valor total do pedido, o que gera uma relação quase determinística entre as variáveis.

Isso implica em um problema conhecido como multicolinearidade estrutural, onde as variáveis estão fortemente correlacionadas por definição, e não por descoberta de padrões nos dados.

Como consequência, o modelo apresenta um R^2 artificialmente elevado e baixo erro residual, o que pode dar uma falsa impressão de capacidade preditiva.

Além disso, o modelo não considera fatores externos relevantes, como comportamento do cliente, sazonalidade, campanhas ou canal de venda, limitando sua aplicabilidade em cenários mais complexos.

Portanto, o modelo é útil para validar a consistência dos dados, mas não deve ser utilizado isoladamente para previsão ou tomada de decisão estratégica.

7. Conclusão da Análise Inferencial

A análise inferencial permitiu validar estatisticamente as relações observadas entre as variáveis, confirmando a consistência dos dados e a relevância das variáveis utilizadas no modelo.

A aplicação de intervalos de confiança e testes de hipótese possibilitou uma compreensão mais aprofundada dos resultados, indo além da simples descrição dos dados.

A análise das campanhas revelou que, embora exista forte influência das ações de marketing no faturamento total, o impacto direto pode variar conforme o contexto, especialmente em períodos de alta sazonalidade.

Isso evidencia que decisões estratégicas não devem se basear apenas em indicadores isolados, mas sim em uma análise mais ampla que considere fatores externos e comportamento do mercado.

Dessa forma, o uso de métodos inferenciais se mostrou fundamental para apoiar decisões mais robustas, reduzindo incertezas e aumentando a confiabilidade das conclusões.